

UNIVERSITATEA POLITEHNICA DIN BUCUREŞTI
FACULTATEA DE AUTOMATICĂ ȘI CALCULATOARE
DEPARTAMENTUL DE CALCULATOARE



PROIECT DE DIPLOMĂ

Aplicație pentru pregătirea examenului de legislație rutieră bazată
pe generarea automată de întrebări

Năstase Maria

Coordonator științific:

Prof. dr. ing. Dumitru-Clementin Cercel

BUCUREŞTI

2024

CUPRINS

| | |
|-----------------------------------------------------|-----------|
| 1 Introducere | 4 |
| 1.1 Tema aleasă | 4 |
| 1.2 Problema | 4 |
| 1.3 Obiective | 5 |
| 1.4 Domeniul din care face parte lucrarea | 5 |
| 1.5 Soluția propusă | 6 |
| 1.6 Structura lucrării | 7 |
| 2 Analiza Cerințelor și motivație | 8 |
| 3 Studiu de Piață și Metode Existente | 10 |
| 3.1 Studiu de Piață | 10 |
| 3.2 Starea Domeniului | 13 |
| 4 Soluția Propusă | 17 |
| 4.1 Baza de date | 17 |
| 4.2 Backend | 18 |
| 4.2.1 Tehnologii folosite | 18 |
| 4.3 Frontend | 18 |
| 4.3.1 Tehnologii folosite | 18 |
| 4.3.2 Detalii de implementare și flux | 19 |
| 4.4 Generarea de întrebări | 26 |
| 4.4.1 Aspecte teoretice | 26 |
| 4.4.2 Modelele utilizate pentru generare | 29 |

| | |
|--------------------------------------------------------------------|-----------|
| 5 Setări experimentale | 32 |
| 5.1 Setul de date utilizat | 32 |
| 5.2 Generarea prin intermediul API-ului oferit de OpenAI | 34 |
| 5.3 Metrici de evaluare | 35 |
| 5.3.1 Exact Match Ratio | 35 |
| 5.3.2 Hamming Score | 35 |
| 6 Concluzii | 36 |
| 6.1 Concluzii | 36 |
| 6.2 Directii viitoare | 36 |

SINOPSIS

Aplicația dezvoltată are ca bază învățarea automată, mai specific domeniul de Procesare a Limbajului Natural, pentru a genera chestionare pentru examenul din legislația rutieră care reprezintă prima etapă din procesul de a obține permisul de conducere. Utilizatorului i se pune la dispoziție opțiunea de a alege ce capitol să revizuiască și îi permite să evalueze greselile făcute în trecut. Întrebările generate sunt specifice capitolului ales, asigurându-se că utilizatorul se poate concentra pe secțiuni particulare ale conținutului legislației rutiere. Generarea se face pe baza unei secțiuni de text dată și rezultatul obținut este reprezentat de întrebarea propriu-zisă și 3 variante de răspuns. Întrebările pot avea mai multe răspunsuri corecte. Setul de date folosit a fost creat pe baza unei cărți de legislație rutieră, care este împărțită pe 18 capitole și prin colectarea grilelor disponibile pe internet. Proiectul constă în utilizarea unor transformatori care dispun de o cantitate mare de resurse computaționale și care au fost antrenate anterior.

ABSTRACT

The developed application is based on machine learning, specifically in the field of Natural Language Processing, to generate questionnaires for the driving law exam, which represents the first step in obtaining a driver's license. The user is provided with the option to select which chapter to review and can evaluate past mistakes. Questions generated are specific to the chosen chapter, ensuring that the user can focus on particular sections of the driving law content. Generation is based on a given text section, resulting in the actual question and three answer options. Questions can have multiple correct answers. The dataset used was created from a driving law book, divided into 18 chapters, and by collecting available online grids. The project involves the use of transformers with extensive computational resources and pre-trained models.

1 INTRODUCERE

1.1 Tema aleasă

Tema aleasă în cadrul lucrării constă în dezvoltarea unei aplicații bazată pe învățare automată, cu scopul de a oferi sprijin persoanelor care se pregătesc pentru susținerea examenului de permis. În prezent, examenul auto este împărțit în 2 etape: proba teoretică (examen scris susținut de către Direcția Regim Permise de Conducere și Înmatriculare a Vehiculelor) și cea practică (examen de conducere, sub supravegherea unui examinator de la DRPCIV). Proiectul de față tratează în mod special prima probă, cea teoretică, prin dezvoltarea unui sistem care generează chestionare personalizate pe baza legislației rutiere, facilitând astfel pregătirea candidaților. În plus, evoluțiile recente în domeniul auto au adus îmbunătățiri în siguranță prin sisteme avansate de asistență pentru șoferi (ADAS) și vehicule autonome. Securitatea rutieră rămâne o prioritate majoră, cu accent pe educația și formarea continuă a șoferilor pentru a reduce accidentele și a îmbunătăți comportamentul în trafic.

Domeniul generării de întrebări prin învățare automată a evoluat considerabil, trecând de la metode bazate pe reguli la utilizarea rețelelor neuronale și a arhitecturilor de tip transformator, precum GPT și BERT. Aceste avansuri au permis crearea de întrebări relevante și coerente din texte, îmbunătățind semnificativ acuratețea și aplicabilitatea în educație și asistență virtuală. Stadiul actual al domeniului utilizează modele pre-antrenate pe seturi mari de date, făcând posibilă generarea automată de întrebări complexe și adaptate contextului specific.

1.2 Problema

Proiectul abordează o problemă esențială în pregătirea pentru examenul teoretic de obținere a permisului de conducere, și anume eficiența procesului de învățare. În prezent, candidații au acces la un număr foarte mare de grile disponibile online, ceea ce duce adesea la memorarea mecanică a răspunsurilor, fără o înțelegere profundă a legislației rutiere. Aceasta metodă de învățare nu este benefică pe termen lung, deoarece nu dezvoltă capacitatea de a gândi critic și de a aplica cunoștințele în situații reale de trafic.

Proiectul propus urmărește să rezolve această problemă prin utilizarea învățării automate și a procesării limbajului natural pentru a genera întrebări unice și variate, adaptate fiecărui capitol al legislației rutiere. Aceste întrebări sunt create din textul de bază, încurajând utilizatorii să

gândească și să înteleagă materialul, în loc să-l memoreze mecanic. Astfel, utilizatorii pot evalua greșelile făcute anterior și pot învăța într-un mod mai eficient și mai aplicat.

Beneficiile acestei abordări includ o mai bună înțelegere a legislației rutiere, pregătirea mai eficientă pentru examenul teoretic și, în final, formarea unor șoferi mai bine pregătiți, capabili să răspundă adecvat în diverse situații de trafic, contribuind astfel la reducerea riscului de accidente.

1.3 Obiective

Scopul principal al aplicației este de a crește rata de promovare a examenului teoretic și de a facilita învățarea activă și comprehensivă, oferind resurse educationale mai eficiente și adaptate nevoilor individuale ale utilizatorilor. Se dorește realizarea unei contribuții la educația rutieră și la formarea responsabili și informați, având potențialul de a îmbunătăți siguranța pe drumurile publice. De asemenea, deși în momentul de față aplicația este destinată exclusiv pregătirii mai concentrate pentru examen, se propune ca în viitor să se implementeze generarea automată de întrebări și în cadrul probei scrisă. Aceasta ar asigura o evaluare mai variată și adaptativă, reflectând mai bine înțelegerea reală a candidaților și contribuind la un proces de examinare mai robust și mai echitabil.

1.4 Domeniul din care face parte lucrarea

Domeniul de cercetare care stă la baza lucrării este Natural Language Processing (NLP), sau Procesarea Limbajului Natural. Aceasta combină lingvistica computațională, informatica și inteligența artificială (AI) pentru a permite calculatoarelor să genereze și să interpreteze limbajul uman. Este un domeniu foarte cercetat, care de-a lungul timpului a devenit o parte integrantă a vieții cotidiene. Aplicațiile NLP includ asistenții virtuali (Siri, Alexa, Google Assistant), traducerea automată (Google Translate), motoarele de căutare (personalizarea rezultatelor căutării bazată pe înțelegerea întrebării) și detectarea și generarea automată de conținut. NLP a evoluat semnificativ în ultimele decenii, progresând odată cu creșterea puterii de calcul. Arhitecturile avansate precum GPT-3 și BERT au revoluționat domeniul, rezultând în înțelegerea și generarea textului cu o acuratețe impresionantă.

Procesarea Limbajului Natural include următoarele componente esențiale:

- **Analiza Sintactică:** Verificarea structurii gramaticale a propozițiilor pentru a asigura conformitatea cu regulile lingvistice. Aceasta cuprinde identificarea părților de vorbire, precum substantive, adjective, verbe și relațiile dintre acestea

- **Analiza Semantică:** Presupune înțelegerea semnificației textului și implică determinarea contextului
- **Procesarea Limbajului de Suprafață:** Include *tokenizarea* (împărțirea textului în cuvinte, subcuvinte/morfeme sau caractere), *stemming-ul* (reducerea unui cuvânt la rădăcina lor fără a ține cont de contextul gramatical) și *lematizarea* (reducerea unui cuvânt la forma de bază, având în vedere contextul gramatical)
- **Recunoașterea Entităților Nominate (NER):** Clasificarea entităților din cadrul textului, cum ar fi locuri, nume de persoane, etc.
- **Generarea Limbajului Natural (NLG):** Crearea textului coerent și natural în limbaj uman pe baza datelor structurate

Machine Learning (ML), sau Învățarea automată se află la baza sistemelor de NLP și reprezintă etapa de antrenare a unor modele pe seturi mari de date lingvistice. Aceste modele pot apoi să facă predicții sau să ia decizii fără a fi explicit programate pentru o sarcină specifică. Recent, impactul învățării automate a crescut considerabil, transformând industrie și îmbunătățind viața de zi cu zi prin oferirea soluțiilor inteligente și prin automatizarea sarcinilor complexe.

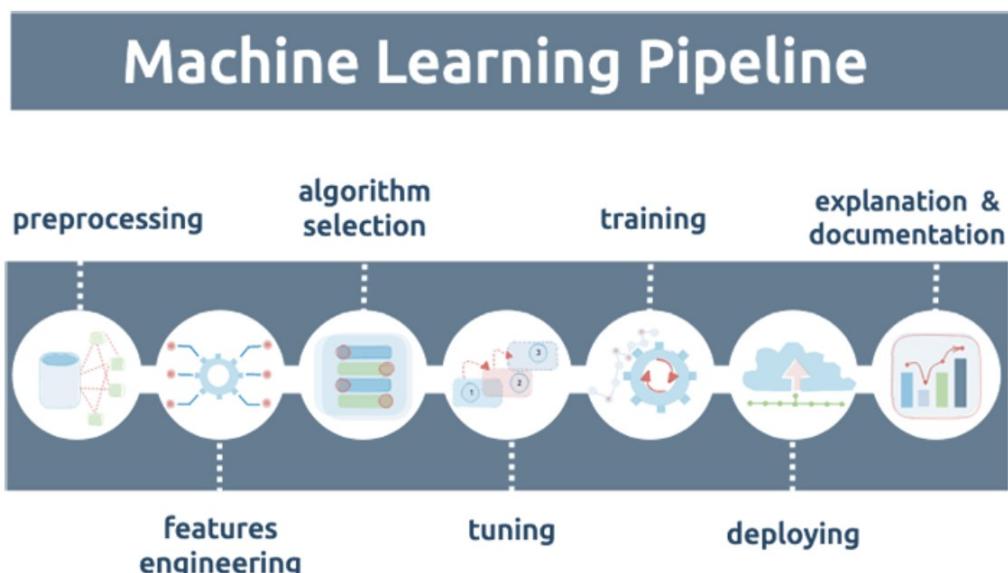


Figura 1: Flux de lucru pentru învățarea automată¹

1.5 Soluția propusă

Aplicația Web implementată este structurată în maniera unei aplicații educaționale standard, având ca principală sursă de inspirație platforma Duolingo. Aceasta dispune de diverse metode pentru a încuraja procesul de învățare, integrând elemente de gamificare și feedback imediat.

¹<https://www.todaysoftmag.ro/article/3619/automat-o-noua-perspectiva-a-invatarii-automate>

Folosind aceste tehnici, se poate asigura sporirea interesului utilizatorului pentru a avea un progres constant. De asemenea, aplicația dispune de lectii zilnice pentru fiecare client, care sunt determinate prin utilizarea Dataset-ului conceput la etapa de generare.

1.6 Structura lucrării

Lucrarea este structurată după cum urmează:

- Secțiunea 1 introduce tematica lucrării, domeniul din care face parte, precum și obiectivele și problematica abordată de proiect
- Secțiunea 2 cuprinde o analiză realizată asupra cerințelor aplicației, impuse de client
- Secțiunea 3 realizează un studiu al pieței și prezintă starea curentă a domeniului
- Secțiunea 4 oferă o descriere detaliată a soluției propuse pentru împlinirea obiectivelor
- Secțiunea 5 este destinată prezentării informațiilor cu privire la setările experimentale (se introduce setul de date utilizat pentru fine-tuning-ul algoritmilor)
- Secțiunea 6 ilustrează concluziile lucrării precum și posibile și aduce în discuție potențiale îmbunătățiri viitoare

2 ANALIZA CERINTELOR SI MOTIVATIE

Conform articolului [2] care pune în evidență situația recentă a susținerii examenului auto, în ultimii ani, școlile de șoferi nu au reușit să obțină o rată de promovabilitate mai mare de 50%. În plus, la nivel de siguranță rutieră, România se află pe ultimul loc în Europa, înregistrându-se un număr mare de decese care au fost cauzate de accidente rutiere.

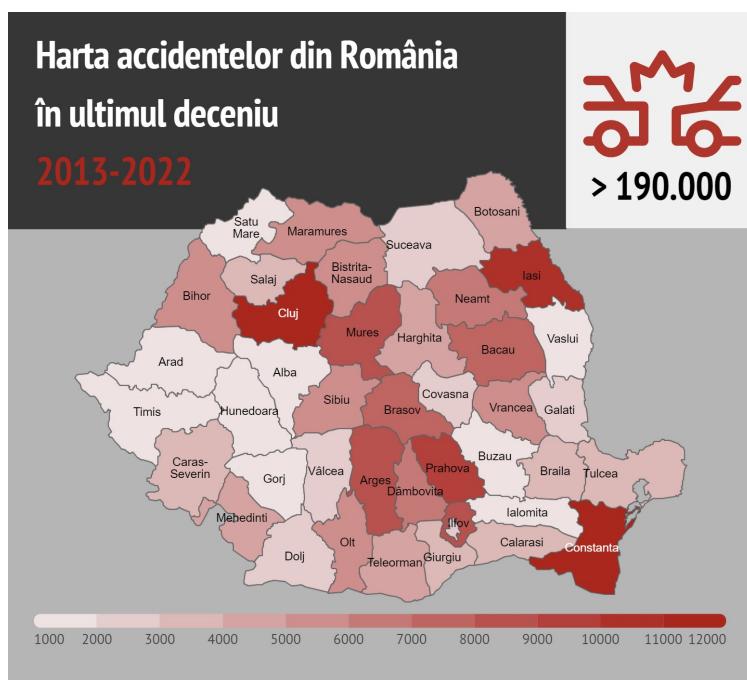


Figura 2: Harta accidentelor din România în perioada 2013-2022¹

Generația prezentă are o dificultate mai mare de a trece de proba teoretică, fapt care se poate datora dezinteresului de a studia cu adevărat legislația. Codul rutier este greu de parcurs și de înțeles, conform spuselor candidaților anteriori, care preferă să memoreze chestionare. Internetul reprezintă o sursă vastă de informații și datorită accesibilității usoare, a devenit o parte integrantă din pregătirea pentru susținerea examenului auto pentru mulți viitori șoferi. Acest fapt este îngrijorător pentru situația traficului din România, deoarece în un candidat ar trebui să aibă cel puțin 24 de ore de pregătire pentru cunoașterea și înțelegerea legislației rutiere, pe când chestionarele disponibile pe internet nu pot oferi această experiență.

Deoarece nu există o cale de a împiedica elevii de la a se baza strict pe chestionare, este esențial să li se ofere o metodă mai bună de a exersa întrebările, care să constituie un mediu mai bun

¹<https://www.g4media.ro/harta-200-000-de-accidente-rutiere-in-ultimii-10-ani-cinci-oameni-mor-zilnic-pe-soselele-din-romania-unde-sunt-cele-mai-multe-accidente-si-victime-primul-loc-in-ue-la-morti-pe-cap-de-loocitor.html>

pentru învățare. Un alt aspect important al pregătirii pentru un examen este motivația. Astfel, o aplicație de chestionare ar trebui să convingă utilizatorul să continue să își îmbunătățească cunoștințele. În plus, este foarte important ca aplicația să aibă o interfață simplă, modernă, care este ușor de navigat pentru orice utilizator.

Un element crucial prezentat de către un instructor care a fost interviewat în articolul [2], este importanța veridicității datelor. Internetul este considerat drept o resursă foarte valoroasă, dar în același timp constituie principalul mediu de răspândire a dezinformării. Site-urile de chestionare care se găsesc online nu au garanția corectitudinii, și de aceea este imperativ ca o aplicație care se bazează pe învățare automată să disponă de un set de date valid, care este revizuit și aprobat de către DRPCIV.

Deși elevii reprezintă baza de utilizatori ai unei aplicații de chestionare, statul român poate, de asemenea, beneficia de anumite funcționalități ale acesteia. Prin implementarea generării dinamice de întrebări, este posibil ca nivelul de dificultate al probei scrise să crească, ceea ce ar putea conduce la o scădere a ratei de promovabilitate. În schimb, noii absolvenți vor fi mai conștienți de lege, deoarece un sistem cu întrebări generate i-ar obliga să învețe efectiv. Astfel, în câțiva ani rata de accidente s-ar putea stabiliza și numărul de mașini ar putea să scadă.

În concluzie, lista de funcționalități esențiale pe care trebuie să le includă o aplicație de chestionare care se bazează pe codul rutier este următoarea:

- **Aspect intuitiv și utilizare facilă:** Interfață simplă și prietenoasă, care permite accesul funcțiilor aplicației fără dificultăți.
- **Mediu de învățare:** Includerea unor cursuri sau lecții scurte pentru a încuraja studiul
- **Metode de menținere a implicării utilizatorului:** Folosirea tehniciilor persuasive pentru a motiva utilizatorul să învețe
- **Corectitudine a datelor:** Asigurarea veridicității și a actualității dataset-ului

3 STUDIU DE PIATĂ ȘI METODE EXISTENTE

3.1 Studiu de Piată

În prezent, se pot găsi un număr mare de site-uri web sau aplicații de mobil care conțin întrebările date la examen, dintre care un singur site este oficial, creat de către MAI (Ministerul Afacerilor Interne). Metoda cea mai bună de învățare constă, de fapt, în asistarea cursurilor de legislație oferite de școala auto, unde un profesor predă codul rutier și se dă teste instructive. Însă, aplicațiile de telefon au mare succes în rândul tinerilor, cărora le displace ideea de a învăța pe îndelete.

În imaginea atașată mai jos, este ilustrat numărul de recenziî acordate de utilizatori pentru cele mai populare aplicații mobile de chestionare.

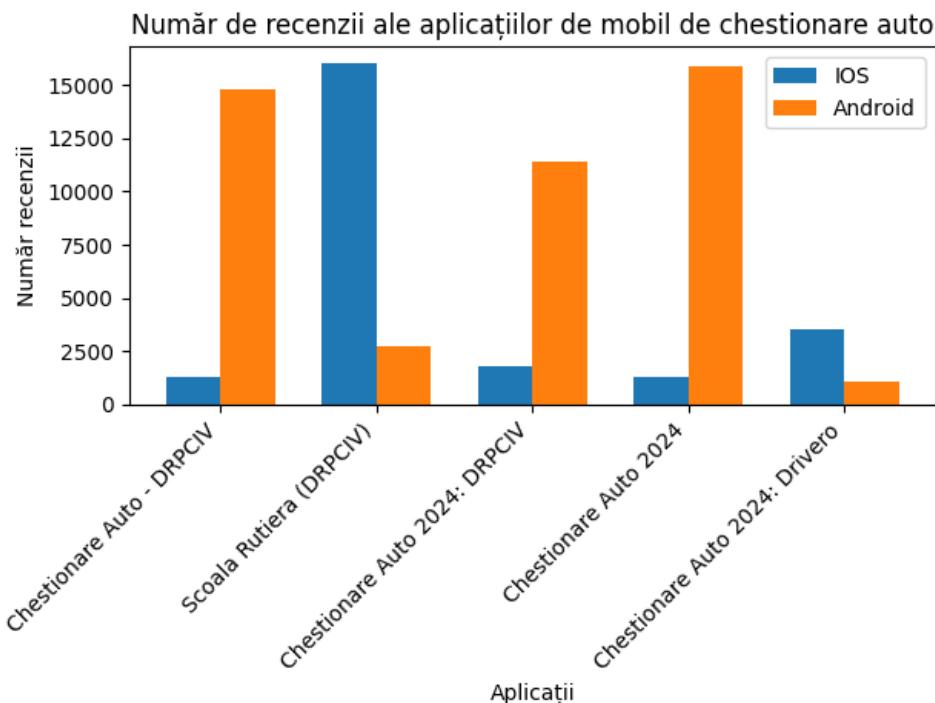


Figura 3: Grafic cu număr de recenziî ale aplicațîilor de chestionare

Analizînd recenziîle utilizatorilor pentru aplicațîile studiate, am observat că în mare parte, aceștia își exprimă insatisfacția cu performanțele și aspectul aplicațîilor. În plus, o altă problemă adusă în discuție este lipsa actualității a codului rutier. Legislația a fost modificată de mai multe ori de-a lungul anilor și este important ca aceste schimbări să fie implementate în aplicațîile pentru a stabili un mediu de învățare exactă.

În ceea ce privește aplicația oficială oferită de DRPCIV, aceasta are o interfață cu un design simplist, este ușor de navigat, și pune la dispoziție posibilitatea de a alege pentru ce categorie se dorește pregătirea. Este menită să simuleze testul computerizat, dar setul de întrebări pentru acest site este limitat, la cererea poliției.



Figura 4: Chestionar Oficial Examen Auto¹

Unul dintre dezavantaje este faptul că aplicația nu oferă feedback pe baza greselilor utilizatorilor, ci doar indică faptul că s-a făcut o greșeală. În plus, la 5 răspunsuri greșite, testul se încheie brusc. Deși își împlinește scopul de a prezenta modul de desfășurare al examenului computerizat, focusul nu este învățarea. Utilizatorii pot să vadă în timp real dacă au dat un răspuns corect sau greșit, dar este foarte greu de progresat dacă nu se cunoaște în prealabil codul rutier. Acest fapt rezultă în alienarea utilizatorului, care va opta pentru alte variante care îi permit să treacă cu repede și cu ușurință prin întrebări.

Un exemplu bun de aplicație educațională, deși nu face parte din domeniul vehiculelor, este Duolingo, care în momentul de față este cea mai mare platformă pentru a învăța limbi. Designul interfeței este plăcut, cu multe animații și imagini care contribuie la estetica aplicației și care sunt menite să atragă tinerii. Aplicația este extrem de ușor de folosit și dispune de diverse tehnici de asigurare a implicării continue a utilizatorului, precum trimiterea insistență a notificărilor și gamificarea procesului de învățare.

Gamificarea implică utilizarea mecanicilor specifice jocurilor pentru a motiva consumatorii. Spre exemplu, Duolingo are clasamente săptămânale, care promovează competitivitatea și rezultă în crearea unui *player base* mai activ. În plus, Duolingo numără zilele consecutive în care un utilizator a fost activ (*Day Streak*), resetând numărul în cauzul în care o zi a fost omisă. Această tehnică favorizează ideea de completare a cel puțin unei lectii pe zi

¹<https://dgpci.mai.gov.ro/dlexam>

și este menită să sporească interesul pentru învățare. Conform articolului [12] introducerea gamificării în cadrul Învățării limbilor asistată de dispozitive mobile (*Mobile-assisted language learning*) a produs rezultate foarte bune, sporind angajamentul și motivația utilizatorilor. În cadrul platformei Duolingo s-au identificat 22 elemente de gamificare, printre care și generarea instantă a feedback-ului când o întrebare a fost răspună greșit. În plus, se permite revizuirea greselilor trecute.

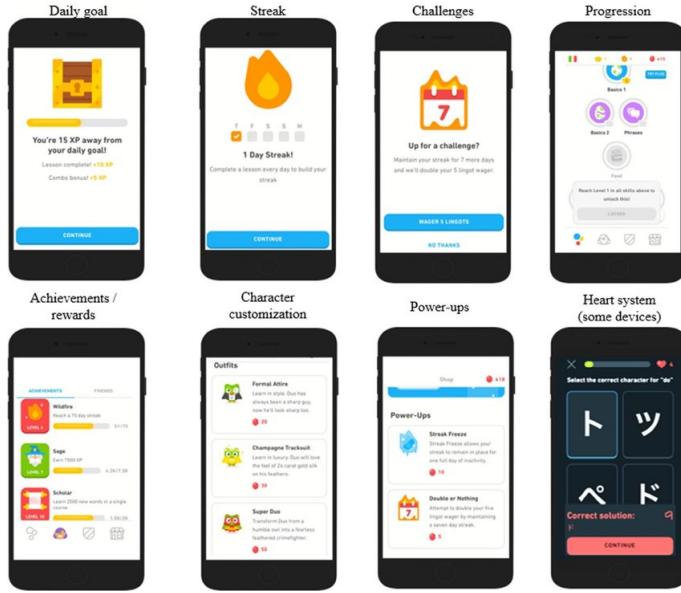


Figura 5: Elemente de gamificare folosite de Duolingo

Duolingo folosește sisteme AI pentru a genera întrebări și propoziții pentru diverse limbi. Modelul de învățare automată utilizat de Duolingo este Birdbrain [3]. Scopul acestui sistem este de a menține interesul utilizatorului prin generarea lecțiilor personalizate (*balansate*) pentru utilizator. Birdbrain estimează atât dificultatea exercițiului, cât și proficiența curentă a utilizatorului, formând lecția perfectă, care se potrivește cu nivelul utilizatorului. Oricând un consumator răspunde la o întrebare, estimările se actualizează. Cea mai recentă versiune a modelului are la bază un long short-term memory (LSTM) care are rolul de a comprima istoricul exercițiilor utilizatorului într-un vector 40-dimensional. Pe baza acestui vector, sistemul poate face predicții asupra performanței utilizatorului în exercițiile următoare.

Scopul aplicației Duolingo este de a mima comportamentul unui tutore, folosind astfel instrumentele de NLP în scopul analizei vocabularului și a gramaticii cursurilor lingvistice din cadrul aplicației. Exercițiile scrise au de obicei variante multiple de răspunsuri corecte, deoarece în anumite cazuri există mai multe metode acceptate de a structura o frază în altă limbă. În plus, trimitera notificărilor se realizează tot pe baza activității utilizatorului [13], folosind informații cu privire la achievement-urile obținute de acesta. Scopul acestora este de a atrage atenția și de a încuraja folosirea aplicației.

3.2 Starea Domeniului

Procesarea limbajului natural este o ramură a inteligenței artificiale care permite dispozitivelor să înțeleagă, să genereze și să manipuleze limbajul uman. NLP are capacitatea de a interoga datele folosind text sau voce în limbaj natural. Natural Language Processing este tehnologia de bază din spatele asistenților virtuali, cum ar fi Siri, Cortana sau Alexa. Când adresăm întrebări acestor asistenți virtuali, NLP este ceea ce le permite să înțeleagă cererea utilizatorului și să răspundă în limbaj natural. NLP se aplică atât textului scris, cât și vorbirii și poate fi utilizat pentru toate limbile umane. Alte exemple de unelte bazate pe NLP includ căutarea pe web, traducerea automată a textului sau vorbirii, sumarizarea documentelor și verificarea gramaticii și ortografiei. De exemplu, unele programe de email pot sugera automat un răspuns potrivit la un mesaj bazat pe conținutul său - aceste programe folosesc NLP pentru a citi, analiza și răspunde mesajului.

Domeniul analizat este acela de generare automată a răspunsurilor pe baza unui text dat prin utilizarea algoritmilor de machine learning . Acest proces este esențial pentru aplicații precum sistemele educaționale, asistenții virtuali și evaluările automate. De asemenea, domeniul este relevant pentru generarea întrebărilor aferente chestionarelor auto, prezentate în această lucrare.

Acest sistem are ca scop generarea de rezultate dorite, într-un limbaj comun, folosind învățarea automată a unor date preluate dintr-o bază de date, sau puse la dispoziție prin alte metode de către utilizator. Preluarea datelor se poate realiza din multiple surse care pun la dispoziție informații relevante pentru subiectul analizat. De la metode tradiționale bazate pe reguli, tehnologia a evoluat semnificativ odată cu apariția algoritmilor de învățare profundă și modelelor generative de limbaj.

În articolul [9] publicat în jurnalul *Multimedia Tools and Applications* primim o imagine cuprinzătoare asupra evoluției și aplicațiilor procesării limbajului natural (NLP) până în anul 2022, precum și asupra tendințelor actuale și provocărilor din acest domeniu. Conform articolului putem identifica două tipuri de modele de limbaj pre-antrenate:

- **BERT (Bidirectional Encoder Representations from Transformers):** BERT a revoluționat NLP prin utilizarea unui model de limbaj bidirecțional care înțelege contextul cuvintelor în ambele direcții. Acest model a îmbunătățit semnificativ performanțele în diverse sarcini NLP, cum ar fi clasificarea textului, analiza sentimentelor și întrebări și răspunsuri.
- **GPT (Generative Pre-trained Transformer):** Modelele GPT, dezvoltate de OpenAI, au demonstrat capacitatea de a genera text coerent și relevant, fiind capabile să producă răspunsuri detaliate și contextuale la întrebările utilizatorilor.

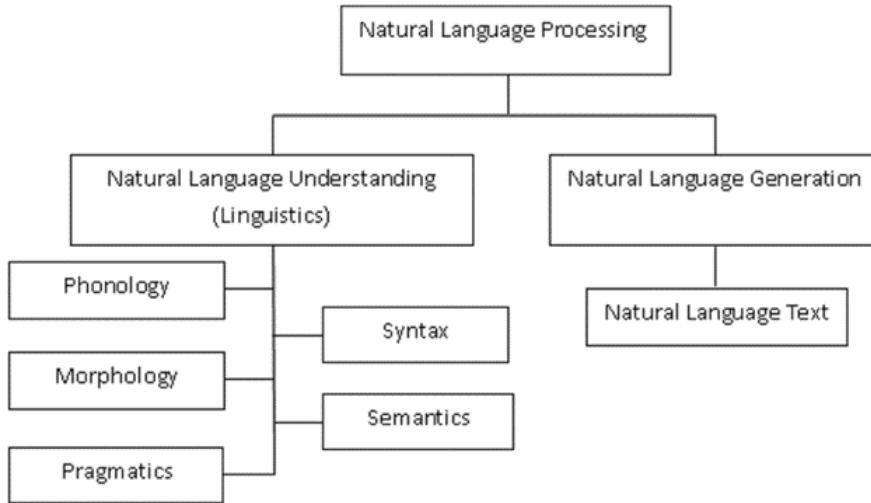


Figura 6: Clasificarea generală a sistemelor NLP

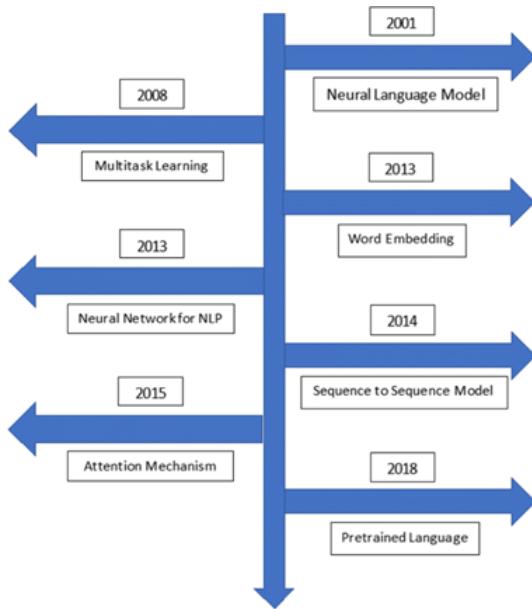


Figura 7: Prezentare evoluții recente în domeniul NLP

Bidirectional Encoder Representations from Transformers a avut un impact semnificativ în domeniul procesării limbajului natural de la introducerea sa de către Google în 2018. Acest model a revoluționat modul în care sunt tratate diverse sarcini NLP prin capacitatea sa de a înțelege contextul bidirecțional al cuvintelor într-o propoziție.

Google a implementat BERT în algoritmul său de căutare, ceea ce a îmbunătățit semnificativ relevanța și precizia rezultatelor de căutare. Prin înțelegerea mai bună a contextului și a intenției utilizatorilor, BERT ajută Google să ofere răspunsuri mai relevante pentru utilizatori.

Diverse companii folosesc BERT pentru a îmbunătăți performanța asistenților virtuali. De exemplu, Amazon utilizează tehnologia similară pentru a îmbunătăți capacitatea Alexa de a înțelege și răspunde la întrebări complexe.

În contextul procesării limbajului natural (NLP), capacitatele actuale ale modelelor avansate, precum ChatGPT-4, sunt remarcabile și variate. Aceste modele sunt capabile să înțeleagă și să genereze limbaj natural cu un nivel ridicat de coerență și relevanță. Ele pot interpreta întrebări complexe și oferi răspunsuri detaliate, pot redacta și rezuma texte, și pot realiza traduceri automate între diverse limbi.

ChatGPT-4, de exemplu, este utilizat pe scară largă în asistență virtuală, unde poate răspunde la întrebări frecvente, poate oferi suport tehnic și poate gestiona interacțiuni de bază cu clienții. Acest model este capabil să recunoască și să analizeze sentimentele din texte, fiind folosit în monitorizarea social media pentru a evalua percepțiile publicului asupra unor produse sau evenimente. De asemenea, poate genera texte creative, cum ar fi povești sau articole, și poate participa la conversații în limbaj natural, făcându-l util în chatboti și alte aplicații de comunicare.

Printre alte realizări majore recente putem aminti din categoria tehniciilor de învățare profundă, adaptarea rețelelor neuronale convoluționale pentru a realiza sarcini de procesare în limbaj natural precum clasificarea textului. De asemenea, rețelele neuronale recurente și „long short-term memory”, folosite ideal pentru procesarea secvențelor de date, traducere automată, predicție de text și analiză temporală a datelor.

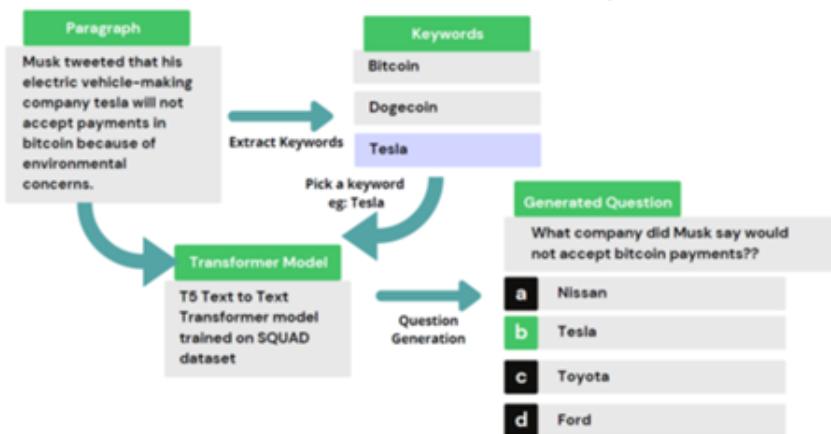


Figura 8: Generare de întrebări folosind QuesGen.AI

QuestGen.AI este o bibliotecă open-source folosită pentru generarea automată a întrebărilor din text. QuestGen este conceput pentru a automatiza procesul de evaluare, ajutând profesorii prin generarea de întrebări multiple-choice, întrebări adevărat/fals, întrebări frecvente, parafrăzări și răspunsuri la întrebări dintr-un text dat.

Conform articolului „Question generation using NLP” publicat de Data Science Milan, QuestGen a demonstrat utilizarea modelului T5 Transformers pentru a genera întrebări multiple-choice. Modelul T5 Transformer reformulează toate sarcinile NLP într-un format text-la-text, unde atât intrarea, cât și ieșirea sunt siruri de text. Este un model encoder-decoder care, dat

fiind un text de intrare, învață să genereze un text de ieșire, mai precis întrebări și răspunsuri potrivite contextului.

Un aspect crucial este înțelegerea corectă a contextului unui cuvânt cheie, iar pentru această activitate se folosesc răspunsuri greșite generate intenționat pentru a descoperi sensul corect al unui cuvânt într-o propoziție. S-au utilizat algoritmii WordNet și Sense2Vec pentru generarea acestor răspunsuri. WordNet este o bază de date lexicală mare a limbii engleze, iar Sense2Vec captează informații contextuale ale unui cuvânt, generând sinonime.

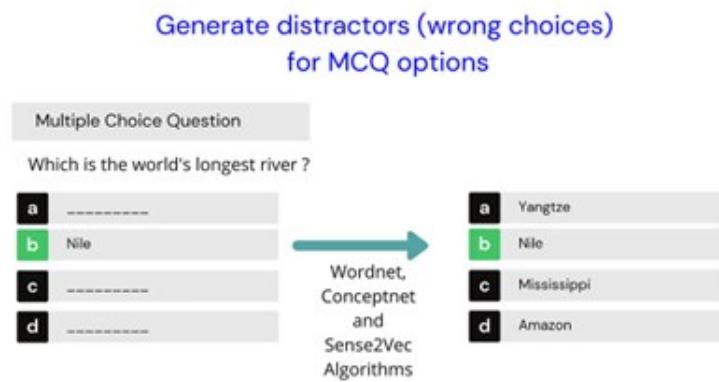


Figura 9: Generare de răspunsuri greșite folosind Wordnet

Generarea întrebărilor cu răspunsuri multiple este mult mai complexă decât cea a variantelor cu un singur răspuns dat fiind numărul de combinații posibile ale răspunsului final. Dar aşa cum am iterat în paragrafele anterioare s-au făcut îmbunătățiri recent în acest sens, dat fiind exemplul QuestGen.AI

4 SOLUȚIA PROPUȘĂ

Proiectul a fost realizat în 4 etape, prezentate mai jos (nu sunt ordonate în funcție de implementare):

- **Baza de date:** Crearea unui database pentru a reține informațiile întrebărilor generate, precum și cele ale utilizatorului
- **Backend:** Stabilirea comunicației cu baza de date (extragere și introducere de date)
- **Frontend:** Dezvoltarea unei interfețe grafice pentru interacțiunea cu utilizatorul
- **Generarea întrebărilor:** Folosirea diversilor algoritmi în scopul generării chestionarelor

4.1 Baza de date

Baza de date se află pe un server local care, care a fost inițiat prin intermediul aplicației Microsoft SQL Server Management Studio. Limbajul SQL utilizat în cadrul aplicației este Microsoft SQL, iar structura tabelelor este următoarea:

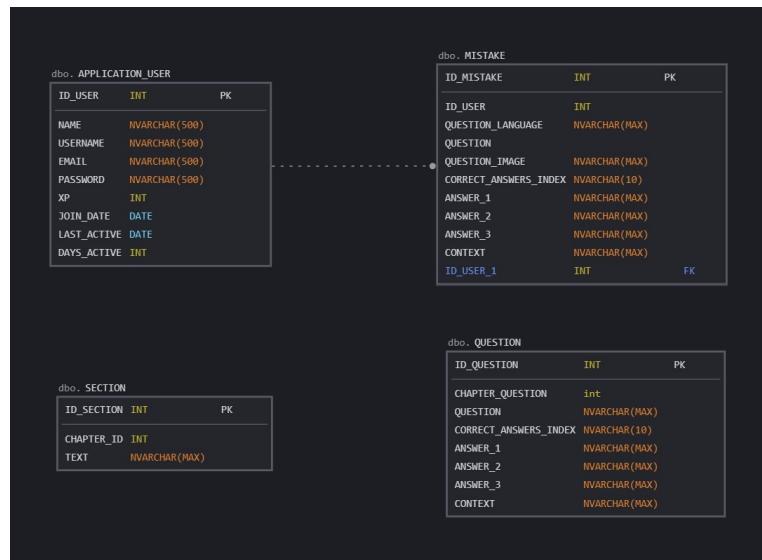


Figura 10: Structura Bazei de Date

Tabela *SECTION* conține întregul dataset care alcătuiește cartea de legislație utilizată, iar entitatea *QUESTION* cuprinde colecția de întrebări originale, precum și cele generate.

Aplicația se conectează la server prin utilizarea parametrilor prezenți mai jos. Deoarece server-ul folosește Windows Authentication, nu este necesară adăugarea parametrilor de user-

name și password, deoarece sistemul folosește credențialele implicite, dar din acest motiv este imperativ ca *Integrated Security* să aibă valoarea *True*.

```
spring.datasource.url=spring.datasource.url=jdbc:sqlserver://localhost:1433;databaseName=QUESTIONNAIRES_DB;integratedSecurity=true  
spring.datasource.driver-class-name=com.microsoft.sqlserver.jdbc.SQLServerDriver  
spring.jpa.hibernate.ddl-auto=none  
spring.jpa.show-sql=true
```

Figura 11: Parametri folosiți la conectarea cu baza de date

4.2 Backend

4.2.1 Tehnologii folosite

Pentru dezvoltarea funcționalităților de Backend, s-a folosit limbajul Java, deoarece este un limbaj simplu, familiar, orientat pe obiect, care este robust și sigur, având performanțe ridicate. Însă, motivul principal pentru utilizarea acestui limbaj constă în puterea framework-urilor dezvoltate pe baza Java. Unul dintre cele mai răspândite și utilizate framework-uri este Java Spring, o platformă care oferă suport complet pentru dezvoltarea aplicațiilor Java și gestionează infrastructura, astfel încât dezvoltatorul se poate concentra pe aplicația la care lucrează [7].

Se setează proprietățile aplicației pentru a asigura conectarea la baza locală, iar dependențele aditionale sunt încărcate în proiect prin intermediul instrumentului Maven (software care gestionează build-ul și documentația pe baza unui fișier, având la bază conceptul de Project Object Model, sau POM).

În scopul asigurării unei comunicații facile cu baza de date, s-a folosit serviciul Hibernate (o modalitate de a lucra ușor și eficient cu informații dintr-o bază de date relațională sub formă de obiecte Java naturale [6]). Folosindu-se concepte de Reverse Engineering, se generează automat cod Java pentru clase de tip Entity care devin corespondenți direcți ai tabelelor bazei de date la care s-a realizat conexiunea. Utilizarea acestui tool este foarte avantajoasă, deoarece schimbările structurii bazei de date nu necesită modificarea manuală a claselor de către developer.

4.3 Frontend

4.3.1 Tehnologii folosite

Limbajele folosite pentru dezvoltarea interfeței grafice sunt TypeScript, HTML și CSS. În plus, m-am folosit de framework-ul Angular pentru a putea dispune de funcționalitățile de reactive

programming și modularitatea oferită de acesta.

Angular este un framework JavaScript open-source, menținut de Google. Platforma este component-based, asta însemnând că orice aplicație Angular este un arbore de componente. Este o rescriere completă a predecesorului său popular, AngularJS [11]. Este o platformă care se află în extindere continuă, fiind în actualizată de două ori pe an. Deși arhitectura framework-ului va rămâne probabil aceeași, versiunile viitoare vor include noi funcții, vor performa mai bine și vor genera pachete de cod mai mici.

Aplicațiile Angular pot fi dezvoltate în JavaScript (folosind sintaxa ECMAScript 5 sau versiuni ulterioare) sau TypeScript. Dar în cazul meu, am ales folosirea limbajului Typescript datorită familiarității, dar motivul principal este faptul că, spre deosebire de JavaScript, acest limbaj poate detecta erorile la timp de compilare, astfel contribuind la robustitatea codului.

4.3.2 Detalii de implementare și flux

Aplicația este împărțită în mai multe pagini care constituie flow-ul aplicației. În scopul implementării componentelor specifice paginilor, s-a apelat la documentația PrimeNG [8], care reprezintă o colecție open source de componente Angular, menită să faciliteze dezvoltarea.

Design-ul aplicației se inspiră în principal din aspectul vizual al platformei Duolingo, îmbinând niște elemente întâlnite care se pot regăsi în aplicațiile dezvoltate pentru MAI, precum și în aplicațiile de chestionare disponibile pe internet.

Pentru a înțelege mai bine structura și funcționalitatea aplicației, fluxul aplicației este prezentat mai jos. Diagrama pune în evidență succesiunea de pagini și butoanele care determină navigarea între pagini.

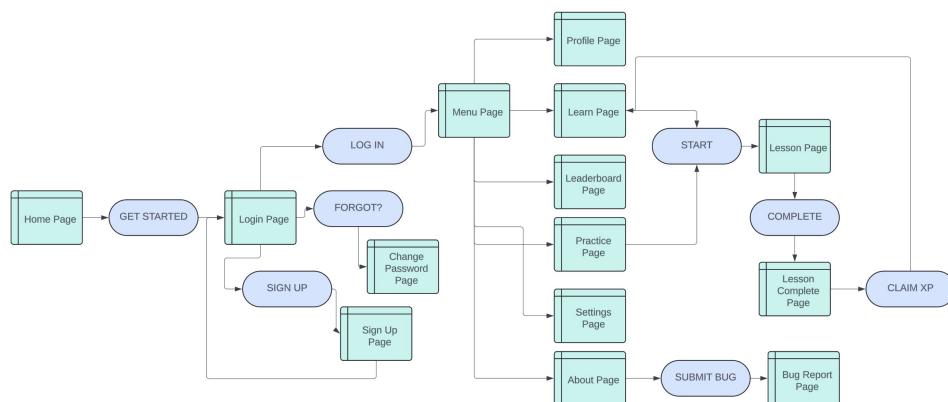


Figura 12: Fluxul aplicației implementate

Paginile de *Autentificare*, *Înregistrare*, *Setări* și *Schimbare a parolei* fac parte din procesul de autentificare a utilizatorului, prelucrându-se astfel datele personale ale acestuia. Este

important să se mențină integritatea datelor utilizatorului și să se asigure protecția acestora. Astfel, pentru a menține un nivel minim de securitate, înainte de a stoca datele utilizatorului, parola este encriptată folosind o metodă de salted hashing. Însă, deoarece în prezent, focusul central al aplicației nu este securitatea, se folosește același Salt pentru encriptarea fiecărei parole, pentru a putea asigura simplitatea verificării parolei din baza de date cu cea introdusă de către utilizator. În consecință, sistemul este expus la riscul unui atac cibernetic. Deoarece se folosește un singur Salt pentru întreaga aplicație, asta ar însemna că atacatorii pot folosi tabele precomputate (Rainbow Tables) pentru a descoperi parolele. Dacă va exista vreodată oportunitatea de a lansa aplicația pe piață, algoritmul de hashing va fi primul aspect care va necesita modificări.

Figura 13: Pagina de autentificare

Figura 14: Pagina de înregistrare

Pagina de *Ajutor* pune discuță posibile întrebări pe care utilizatorii le-ar putea adresa pe viitor. Scopul acestea este de a reprezenta un mic ghid de utilizare pentru utilizatorii nou-veniți. Se dorește ca pe viitor să se primească feedback de la clienți, iar întrebările puse de acestia vor fi adăugate la această pagină.

The screenshot shows a user interface for a help page. At the top right is a close button (X). Below it is the title "Întrebări frecvente". The page is divided into sections: "Utilizarea Drive Smart" and "Gestionarea contului". Under "Utilizarea Drive Smart", there are two collapsed dropdowns: "Cum utilizez Drive Smart pentru pregătirea chestionarelor?" and "Cum urmăresc progresul meu?". Under "Gestionarea contului", there are three collapsed dropdowns: "Cum îmi schimb numele de utilizator sau adresa de email?", "Întâmpin probleme la accesarea contului meu", and "Cum îmi sterg contul?". At the bottom left is a question "Încă ai nelămuriri?", and at the bottom center is a blue button labeled "TRIMITE RAPORT DE EROARE".

Figura 15: Pagina de Ajutor

Din cadrul paginii de Ajutor, se poate accesa raportul de eroare. Acesta este folosit deoarece permite utilizatorilor să transmită feedback direct către administratorii platformei. Acest proces este esențial pentru dezvoltarea continuă a aplicației.

The screenshot shows a report error form. At the top right is a close button (X). The title is "Cu ce vă putem ajuta?". The form has several input fields: "Descrieți problema" (with placeholder text about describing the problem), "Adresa dumneavoastră de email", "Subiect", "Descriere" (a large text area), and "Tipul problemei" (a dropdown menu with placeholder text "VĂ RUGĂM SĂ SELECTAȚI UNA..."). At the bottom right is a blue "TRIMITE" button.

Figura 16: Raportul de Eroare

Pagina de schimbare a parolei este formată dintr-o componentă de Email, iar utilizatorul care și-a uitat parola este sfătuit să își introducă email-ul pentru ca mai apoi să primească un mail generat care conține indicații asupra pașilor de schimbare a parolei.



Figura 17: Raportul de Eroare

Odată ce se trece de pasul de autentificare, utilizatorul este redirectat la meniul principal care conține o bară laterală de navigare pentru a facilita comutarea între paginile dashboard-ului.

 A screenshot of the main menu of the Drive Smart application. On the left is a sidebar with icons for "ÎNVĂȚĂ" (Learn), "EXERSEAZĂ" (Exercise), "CLASAMENT" (Ranking), "PROFIL" (Profile), and "MAI MULTE" (More). The main content area is titled "Învăță" and lists several sections with icons and descriptions:

- Reguli generale**: Noțiuni întâlnite în legislația rutieră
- Indicatoare și marcaje**: Indicatoarele și marcajele rutiere: semnificație și importanță în trafic.
- Semnale luminoase și sonore**: Utilizarea semnalelor luminoase și sonore pentru a comunica în trafic.
- Semnalele polițiștilor**: Semnalele polițiștilor: cum să le interpretezi corect pentru siguranță ta.
- Pozită în timpul mersului și semnalele conducătorului de autovehicule**: Poziția corectă pe drum și semnalele pe care trebuie să le folosească conducătorii auto.
- Depășirea**: Reguli și precauții pentru efectuarea depășirilor în siguranță.
- Viteză și distanță între vehicule**: Reguli privind viteză de deplasare și menținerea distanței corespunzătoare între vehicule.
- Reguli referitoare la manevre**: Manevrele de bază în trafic și regulile aferente acestora.

Figura 18: Meniul principal al aplicației

Mediul de învățare este constituit din paginile *Învăță* și *Exersează* care reprezintă un entrypoint pentru exersarea chestionarelor, sau accesarea unor lecții zilnice. Pe de altă parte, secțiunile *Clasament* și *Profil* se focusează pe statisticile utilizatorului, punând în evidență mecanicile specifice jocurilor care au fost implementate în cadrul proiectului. Butonul intitulat *Mai multe* deschide o componentă de tip dialog, de unde se pot accesa Setările, pagina de *About*, sau se poate ieși din cont.

Selectarea unui capitol de la categoria de Învățare va rezulta în deschiderea paginii de chestionar, care extrage date alese aleator din bază, dar care corespund capitolului ales. Numărul maxim de întrebări din cadrul unei lecții este întotdeauna 26, același număr ca în examenul

propriu-zis. Acest fapt se datorează dorinței de a putea simula condițiile de examen. Spre deosebire de aplicația oficială dispusă de către DRPCIV, utilizatorului îi este permis să vadă ce a greșit și i se oferă instant feedback. De asemenea, testul nu se termină la 5 greșeli, și pagina chestionarelor conține un Progress Bar, similar cu Duolingo. Odată ce utilizatorul termină setul de întrebări, acesta primește un raport scurt cu privire la performanța sa, iar greșelile sunt înregistrate în baza de date.

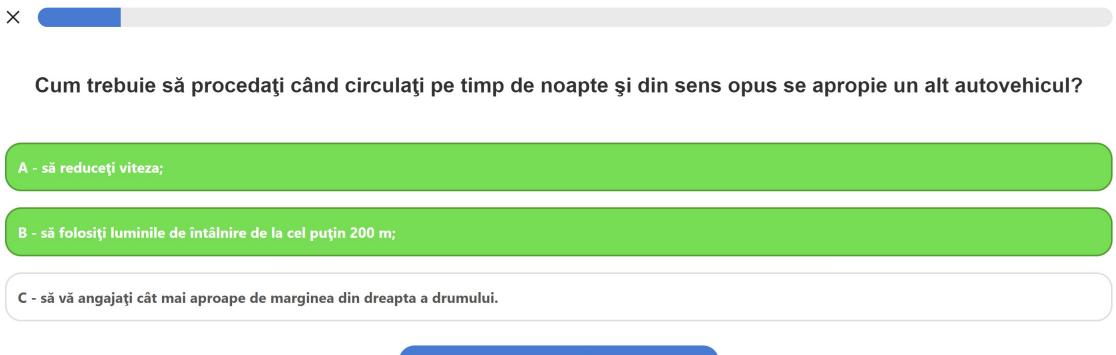


Figura 19: Pagina de chestionare

Este important de menționat faptul că etapa de generare nu are loc la comunicarea cu Backend-ul. Sistemele de învățare automată folosite în cadrul aplicației sunt destul de încete, ceea ce ar rezulta în încetinirea considerabilă a performanței aplicației care ar aștepta un răspuns de la Backend. Pentru a putea folosi în timp real sistemele implementate pentru generarea întrebărilor este nevoie de o putere mai mare de computabilitate.

Rolul paginii de exersare este de a prezenta utilizatorului ce greșeli a făcut în trecut. Aceasta are posibilitatea de a elimina întrebările care au fost revizuite și înțelese deja. Din cadrul acestei pagini se poate începe să rezolve un test, dar de data aceasta, întrebările fac parte din setul de greșeli făcute de utilizator în trecut. Tot din această pagină, un user poate să acceseze o lecție scurtă de legislație, care se schimbă zilnic. Scopul includerii unei lecții personalizate este de a spori interesul clientilor pentru studierea fără asistență, fără ca acestia să se simtă supraîncărcați cu informații.

În ceea ce privește pagina de profil, aceasta ilustrează datele utilizatorului, precum și statistici referitoare la progresul acestuia. Prima statistică reprezintă numărul de zile în care utilizatorul a rezolvat cel puțin un test, iar XP-ul reprezintă punctele acumulate în săptămâna curentă. Pentru un chestionar, acă toate răspunsurile date sunt corecte, atunci se obțin 30 XP. Pentru a oferi utilizatorului o experiență mai personalizată, s-a implementat un API care stochează în sistemul de fișiere pozele de profil ale clientilor. Acestora li se acordă permisiunea de a încărca fotografii personale, conferindu-le posibilitatea de a-și edita profilul și de a-și exprima personalitatea. De asemenea, clasamentul oferă o modalitate de a vizualiza profilurile celorlalți

utilizatori, atât timp cât conturile lor sunt setate ca fiind publice.

The screenshot shows the 'Review-ul de astăzi' (Today's Review) section. At the top right is a language setting 'LIMBA SITE-ULUI: ROMÂNĂ'. On the left, there's a sidebar with icons for 'INVATĂ', 'EXERSEAZĂ' (highlighted in blue), 'CLASAMENT', 'PROFIL', and 'MAI MULTE'. The main area features a circular icon with a refresh symbol and the text 'Examinați greșelile recente'. A large blue 'START' button is centered. Below it are two sections: 'Greșeli' (Recent mistakes) with the text 'Vezi greșelile pe care le-ai făcut în trecut și îmbunătățește-ți cunoștințele' and 'Lecție zilnică' (Daily lesson) with the text 'Invată câteva întrebări noi în fiecare zi'. An illustration of a person sitting at a desk with a car model and various road signs is shown.

Figura 20: Pagina de exersare

The screenshot shows the user profile page for 'Maria Nastase'. The sidebar on the left is identical to Figure 20. The main area displays the user's name 'Maria Nastase' and the date 'Înregistrat în 24 iunie'. Below this is a decorative graphic with travel-related icons like a map, airplane, camera, and luggage. A 'Statistici' (Statistics) section shows '2 Număr de zile' and '16 XP Total'. The overall design is clean with a blue color scheme.

Figura 21: Pagina de profil

Conform articolului [4], îmbunătățirea motivației și implicării în sarcinile de învățare reprezintă principalul motor pentru adoptarea tehniciilor de gamificare, adică pentru a face învățarea mai atractivă, captivantă și, în cele din urmă, eficientă. Luând această informație în considerare, precum și succesul aplicațiilor educationale cu un game based approach, am hotărât să implementez la rândul meu tehnici întâlnite în jocuri video. Clasamentul, calcularea XP-ului, precum și determinarea activității unui utilizator au fost dezvoltate cu scopul de a menține convinge utilizatorul să petreacă mai mult timp folosind aplicația. De asemenea, utilizarea imaginilor și a pictogramelor colorate conferă aplicației un aspect mai atrăgător și prietenos, prezentând procesul de învățare într-o manieră plăcută și distractivă.

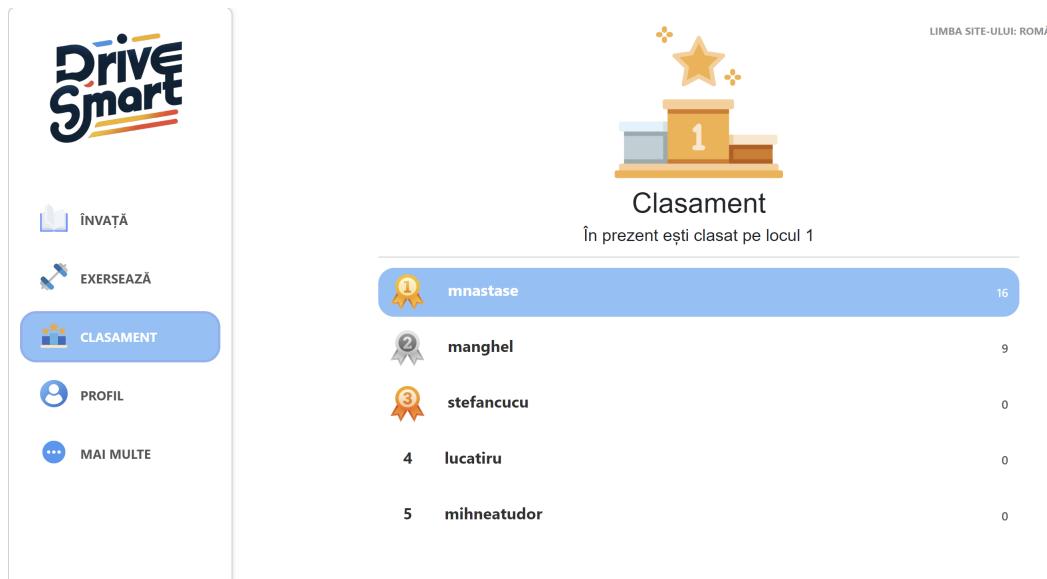


Figura 22: Pagina de clasament



Figura 23: Exemplu de tehnică de gamificare utilizată

Adițional, interfața dispune de o componentă prin intermediul căreia se poate schimba limbajul folosit în cadrul aplicației. Însă, nu are efect asupra textului întrebărilor, care sunt extrase din baza de date, fiindcă traducerea se face prin intermediul modulului i18n (traducere simplă și ușoară, cu stocare dinamică în format JSON). Componenta are scopul de a favoriza un mediu ospitalier pentru străinii care vor să susțină la rândul lor examenul de permis. În prezent, aceasta funcționează doar pentru limbile Română și Engleză, dar în timp ar trebui să se adauge alte limbi, de exemplu Maghiara. Componenta este elaborată pe baza unei componente similare, utilizate în alte aplicații DRPCIV, și este prezentă în majoritatea paginilor aplicației. Astfel, utilizatorului i se oferă posibilitatea de a schimba limbă în orice moment.

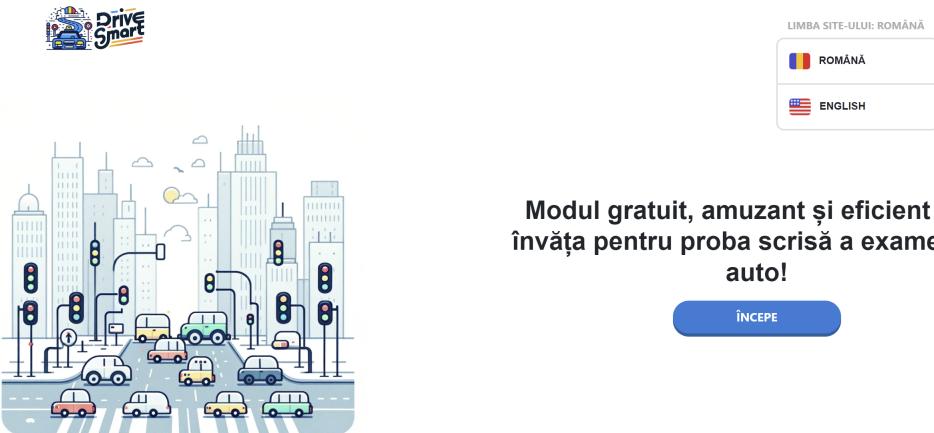


Figura 24: Pagina Home și butonul de schimbare a limbii

4.4 Generarea de Întrebări

4.4.1 Aspecte teoretice

Taxonomiile Educaționale

Taxonomiile educaționale sunt cadre teoretice utilizate pentru a clasifica obiectivele educaționale, scopurile și rezultatele învățării. Acestea permit educatorilor, cercetătorilor și dezvoltatorilor de programe să să evalueze procesele de predare și învățare. Acestea sunt, în general, concepute pentru a descrie diferite niveluri de cunoaștere și abilități pe care elevii ar trebui să le atingă în cadrul unui program de studiu.

Taxonomia Bloom dezvoltată în 1956 de Benjamin Bloom este unul dintre cele mai utilizate cadre teoretice pentru clasificarea obiectivelor educaționale și generarea de întrebări. Se împarte în 6 niveluri cognitive, fiecare reprezentând un nivel diferit de complexitate și profunzime a înțelegерii

- **Cunoaștere:** Implică recunoașterea și reamintirea faptelor și conceptelor. Întrebările la acest nivel sunt de obicei simple și directe, cum ar fi „Ce este fotosinteza?”
- **Înțelegere:** Se referă la explicarea ideilor sau conceptelor. Întrebările pot include „De ce este importantă fotosinteza pentru plante?”
- **Aplicare:** Acest nivel implică utilizarea informațiilor în situații noi. De exemplu, „Cum ar fi afectate plantele dacă fotosinteza nu ar mai avea loc?”.
- **Analiză:** Presupune descompunerea informațiilor în părți componente și înțelegerea structurii acestora. Întrebările de tip „Care sunt etapele procesului de fotosintează?”

sunt comune la acest nivel.

- **Sinteză:** Implică combinarea elementelor pentru a forma un întreg nou. Întrebări precum „Cum ai putea explica fotosinteza unui copil?” sunt reprezentative pentru acest nivel.
- **Evaluare:** Acest nivel se concentrează pe judecarea valorii sau meritelor informațiilor sau ideilor. Întrebări de genul „Cum ai evalua importanța fotosintizei în ecologia globală?” sunt tipice.

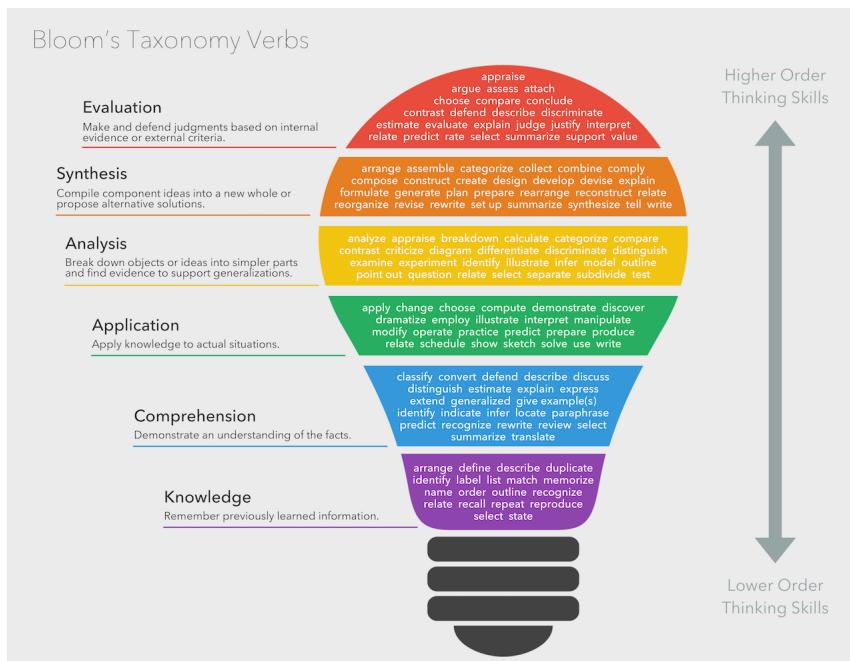


Figura 25: Taxonomia Bloom

Taxonomia SOLO Taxonomia Structure of Observed Learning Outcome (SOLO), dezvoltată de John Biggs și Kevin Collis, este un alt cadru teoretic important pentru evaluarea complexității învățării. Aceasta include cinci niveluri:

- **Prestructural:** Indică lipsa înțelegерii. Întrebările la acest nivel sunt destinate să identifice absența cunoștințelor de bază.
- **Unistructural:** Se concentrează pe înțelegerea unui aspect singular. Întrebările pot fi simple și directe, verificând cunoștințele unui singur concept.
- **Multistructural:** Implică înțelegerea mai multor aspecte, dar fără conexiuni între ele. Întrebările pot testa cunoștințe multiple, dar izolate.
- **Relational:** Se referă la conectarea mai multor aspecte și înțelegerea relațiilor dintre ele. Întrebările pot explora interconexiuni între concepte.
- **Abstract Extins:** Implică generalizarea și transferul înțelegерii la noi domenii. Întrebările necesită aplicarea cunoștințelor în contexte noi.

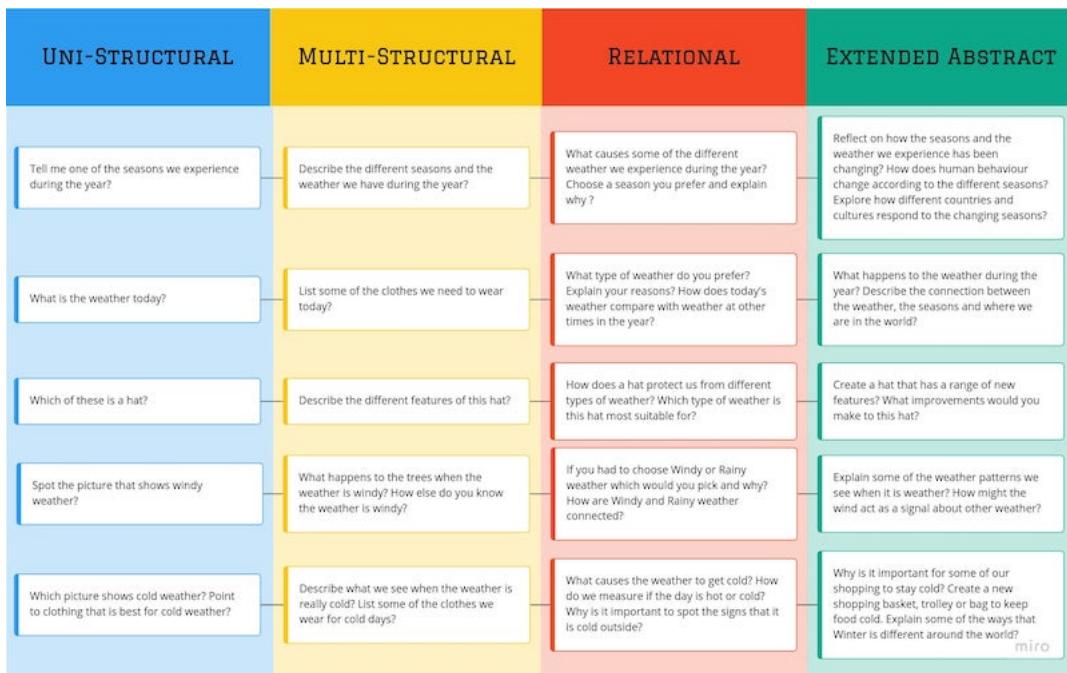


Figura 26: Taxonomia SOLO

Tehnici de Elaborare a Întrebărilor

- **Întrebări Deschise:** Permit răspunsuri extinse și variate, promovând gândirea critică și creativitatea. Exemple includ „Cum ar putea tehnologia să schimbe viitorul educației?”
- **Întrebări Închise:** Necesită răspunsuri scurte și precise, adesea „da” sau „nu”. Exemple includ „Este tehnologia importantă în educație?”.
- **Întrebări de Tip Socratic:** Implică punerea de întrebări secvențiale pentru a stimula reflectia și dezbaterea. Întrebările socratice sunt concepute pentru a încuraja gândirea critică și pentru a adânci înțelegerea unui subiect.
- **Întrebări de Clarificare:** Sunt utilizate pentru a obține explicații suplimentare și pentru a clarifica răspunsurile ambigu. Exemple includ „Ce înțelegi prin aceasta?”.
- **Întrebări de Probing:** Încurajează dezvoltarea răspunsurilor initiale și oferirea unor detalii suplimentare. Exemple includ „Poți să-mi dai un exemplu?”.

4.4.2 Modelele utilizate pentru generare

În cadrul lucrării s-au folosit următoarele modele XLM-RoBERTa [10] și BERT-base-romanian-cased-v1 [5], acestea fiind fine-tuned pentru a putea respecta cerințele aplicației de generare a întrebărilor cu răspuns multiplu în limba română. În plus, s-a folosit și modelul gpt-3.5-turbo, a cărui accesibilitate este asigurată de OpenAI. Însă, acesta nu poate fi fine-tuned.

GPT

Modelul transformator generativ (cunoscut și sub numele de GPT, de la Generative Pre-trained Transformer) este o arhitectură neurală care a revoluționat domeniul prelucrării limbajului natural. Modelul GPT este pre-antrenat pe un set masiv de date text nestructurat. În această fază, modelul învăță să prezică cuvintele următoare din contextul curent.

După pre-antrenare, modelul este optimizat pe sarcini specifice, cum ar fi traducerea, răspunsurile la întrebări sau generarea de texte. Optimizarea îi permite să se adapteze la sarcini specifice.

Modelul GPT se bazează pe arhitectura transformatorului, care utilizează atenția multiplă pentru a captura relațiile dintre cuvinte într-un text. Stratul de atenție permite modelului să se concentreze pe părți relevante ale contextului, indiferent de distanța dintre cuvinte.

GPT generează texte în mod auto-regresiv, adică prezice cuvintele unul câte unul, luând în considerare contextul anterior. Acest proces de generare este lent, dar permite modelului să creeze texte coerente și naturale.

GPT-1, GPT-2, GPT-3 și cel mai recent GPT-4, au diferite dimensiuni ale rețelei, măsurate în numărul de parametri (ponderi ale neuronilor). Cu cât modelul are mai mulți parametri, cu atât este mai capabil să înțeleagă contextul și să genereze texte mai complexe.

| Modelul GPT | Număr parametri |
|-------------|-----------------|
| GPT-1 | 117 milioane |
| GPT-2 | 1.5 miliarde |
| GPT-3 | 175 miliarde |
| GPT-4 | 1.76 trilioane |

Figura 27: Număr parametri pentru model GPT

BERT-base-romanian-cased-v1

Modelul BERT-base-romanian-cased-v1 este o versiune specializată a modelului BERT (Bidirectional Encoder Representations from Transformers) creată pentru limba română.

Modelul are o arhitectură de bază BERT, care include 12 straturi (layers) de transformatoare, fiecare cu 12 atenții. Dimensiunea încorporărilor este de 768, iar dimensiunea totală a parametrilor este de aproximativ 110 milioane. Modelul a fost pre-antrenat pe un volum mare de date textuale în limba română, provenite din diverse surse precum OPUS și Wikipedia.

| Model | UPOS | XPOS | NER | LAS |
|------------------------------|-------|-------|-------|-------|
| bert-base-multilingual-cased | 97.87 | 96.16 | 84.13 | 88.04 |
| bert-base-romanian-cased-v1 | 98.00 | 96.46 | 85.88 | 89.69 |

Corpus

The model is trained on the following corpora (stats in the table below are after cleaning):

| Corpus | Lines(M) | Words(M) | Chars(B) | Size(GB) |
|-----------|----------|----------|----------|----------|
| OPUS | 55.05 | 635.04 | 4.045 | 3.8 |
| OSCAR | 33.56 | 1725.82 | 11.411 | 11 |
| Wikipedia | 1.54 | 60.47 | 0.411 | 0.4 |
| Total | 90.15 | 2421.33 | 15.867 | 15.2 |

Figura 28: Descriere Corpus BERT-base-romanian-cased-v1

XLM-RoBERTa

Modelul XLM-RoBERTa reprezintă o variantă a modelului RoBERTa (Robustly optimized BERT approach) adaptată pentru înțelegerea și procesarea textului în mai multe limbi. Creat de către Facebook AI, acest model se bazează pe arhitectura Transformer și este pre-antrenat pe un set vast și diversificat de date textuale care acoperă 100 de limbi, inclusiv limba română. Spre deosebire de modelele multilingve anterioare, XLM-RoBERTa utilizează o abordare de

pre-antrenare mai robustă, care include o cantitate mult mai mare de date și un set mai diversificat de tehnici de preprocesare. Modelul nu face distincție între majuscule și minuscule.

Datorită acestei pre-antrenări extinse, XLM-RoBERTa se evidențiază în sarcini de procesare a limbajului natural (NLP) precum clasificarea textului, recunoașterea entităților numite, traducerea automată și completarea automată a textului. Modelul beneficiază de capacitatea de transfer a cunoștințelor între limbi, ceea ce înseamnă că performanța sa în limbi mai puțin reprezentate poate fi îmbunătățită datorită datelor disponibile în limbi mai frecvent utilizate. Această caracteristică este deosebit de valoioasă pentru comunitățile lingvistice mai mici sau pentru limbile cu resurse limitate.

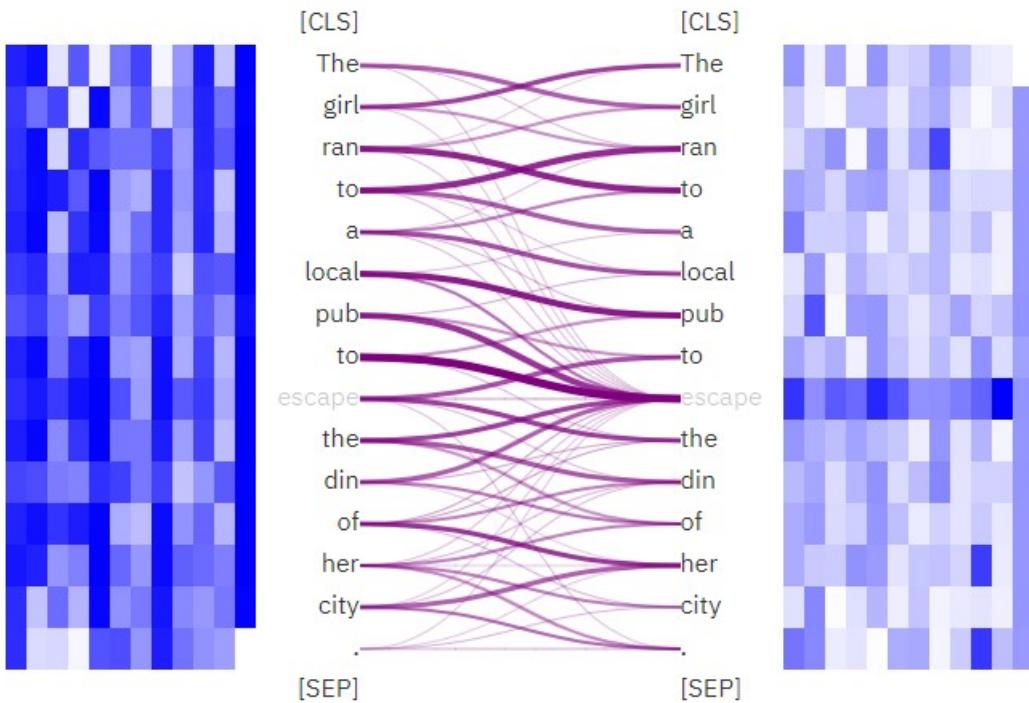


Figura 29: Analiză BERT

5 SETĂRI EXPERIMENTALE

Limbajul de programare utilizat pentru toate scripturile de procesare, antrenare și execuție a modelelor OpenAI este Python. Framework-urile relevante care au fost utilizate în cadrul proiectului sunt scikit-learn, transformers și openai, iar pentru introducerea datelor în Database s-a folosit sqlite. Stația de lucru pe care a fost realizată antrenarea are specificațiile:

- **Tip Procesor:** 13th Gen Intel(R) Core(TM) i9-13900H 2.60 GHz
- **RAM instalat:** 32.0 GB
- **Tip Sistem:** 64-bit operating system, x64-based processor
- **GPU:** NVIDIA GeForce RTX 3050 4GB Laptop GPU

5.1 Setul de date utilizat

Setul de date utilizat are în componiție 2 seturi de date:

- Pe baza textului cursului de legislație
- Pe baza întrebărilor disponibile

Deoarece legislația oficială este o carte lungă, și dificilă de înțeles chiar și pentru elevi (fapt care se datorează formatării), s-a optat pentru folosirea unei cărți care explică în detaliu codul rutier actualizat pentru anul 2024. Textul care a fost folosit pentru a crea setul de date se poate găsi la pagina web [1], site-ul fiind recomandat de colegii de la muncă deoarece cursul oferit este actualizat și oferă o explicație bună a codului rutier. Cartea este structurată în 18 capitole, care constituie fundamentul dezvoltării elevului într-un șofer competent.

- **Reguli generale:** Notiuni întâlnite în legislația rutieră
- **Indicatoare și marcaje:** Indicatoarele și marcajele rutiere: semnificație și importanță în trafic
- **Semnale luminoase și sonore:** Utilizarea semnalelor luminoase și sonore pentru a comunica în trafic
- **Semnalele polițiștilor:** Semnalele polițiștilor: cum să le interpretezi corect pentru siguranță ta
- **Pozitia în timpul mersului și semnalele conducătorului de autovehicule:** Poziția corectă pe drum și semnalele pe care trebuie să le folosească conducătorii auto

- **Depășirea:** Reguli și precauții pentru efectuarea depășirilor în siguranță
- **Viteza și distanța între vehicule:** Reguli privind viteza de deplasare și menținerea distanței corespunzătoare între vehicule
- **Reguli referitoare la manevre:** Manevrele de bază în trafic și regulile aferente acestora
- **Intersecții și prioritate de trecere:** Reguli de prioritate și comportamentul la intersecții
- **Trecerea la nivel cu calea ferată:** Trecerea în siguranță la nivel cu calea ferată: reguli și recomandări
- **Oprirea, staționarea și parcarea:** Reguli privind oprirea, staționarea și parcarea vehiculelor
- **Circulația pe autostrăzi:** Reguli speciale și comportament pe autostrăzi
- **Obligațiile conducătorilor de vehicule:** Obligațiile pe care trebuie să le respecte conducătorii de vehicule
- **Infracțiuni, contravenții și sanctiuni:** Tipuri de infracțiuni și contravenții rutiere și sanctiunile aplicabile
- **Noțiuni de mecanică:** Noțiuni de bază de mecanică auto pentru șoferi
- **Măsuri de prim ajutor:** Măsuri de prim ajutor în caz de accidente rutiere
- **Conducerea preventivă:** Principii și practici ale conducerii preventive pentru siguranța rutieră
- **Conduita ecologică:** Conduita ecologică în conducerea vehiculelor și impactul asupra mediului

Construcția setului de date pe baza cursului este similară cu structura dataset-ului FairytaleQA [14]. Acest Dataset conține fișiere CSV pentru 278 de basme, care mai apoi sunt împărțite pe paragrafe. Astfel, dataset-ul este la rândul său împărțit pe capitole (echivalent poveștilor din FairyTaleQA Data), care mai apoi sunt secționate. Deoarece paragrafele capitolelor erau prea scurte, acestea au putut fi îmbinate (dacă contextul se potrivește), obținând secțiuni care nu depășesc limita impusă de 150 de caractere. Această limită se respectă deoarece altfel, s-ar pierde mai ușor contextul și procesul de generare ar încetini. În prezent, algoritmii de procesare a limbajului natural funcționează mai eficient cu texte scurte, care în mod normal sunt mult mai ușor de citit și înțelese.

Setul de întrebări a fost colectat din cadrul bazei de date a DRPCIV-ului pe care am putut-o accesa cu acordul colegilor de muncă și are următoarea structură. Deși există multe surse online, am optat pentru folosirea întrebărilor oficiale care au fost actualizate în 2024. Pentru a facilita procesul de adăugare a întrebărilor în baza de date, fișierele CSV au fost structurate similar.

```
{
  "id": 1,
  "question": "Punctele de penalizare se aplică pentru:",
  "correct_answers_index": "3",
  "answer_1": "A - nerespectarea semnificației indicatorului 'Copii';",
  "answer_2": "B - nerespectarea semnificației indicatorului 'Drum cu denivelări';",
  "answer_3": "C - nerespectarea semnificației indicatorului 'Oprire', instalat la trecerea la nivel cu o cale ferată.",
  "context": "(1) Săvârsirea de către conducătorul de autovehicul sau tramvai a uneia sau mai multor contraventii atrage"
}
```

Figura 30: Structura unei întrebări convertită în format JSON

În urma procesării datelor am obșinut un set de date cu statisticile care corespund fiecărei etape, anume antrenare, validare și test.

| Setul de date | Numărul instanțelor |
|------------------|---------------------|
| Antrenare | 1707 |
| Validare | 205 |
| Test | 387 |
| TOTAL | 2299 |

Figura 31: Distribuția datelor

5.2 Generarea prin intermediul API-ului oferit de OpenAI

```
def generate_questions_section(prompt_text, questions, chapter):
    openai.api_key = API_KEY

    # Generate questions using GPT-3.5
    response = openai.chat.completions.create(
        model="gpt-3.5-turbo",
        messages=[
            {"role": "system", "content": "Ești un asistent util care generează în format JSON maximum 3 întrebări cu 3 variante de răspuns pe baza textului furnizat. Pot fi mai multe răspunsuri corecte, iar parametrii JSON sunt: question, correct_answers_index, answer_1, answer_2, answer_3. Indexul răspunsului începe de la 1 și formatul variantelor de răspuns este: LITERA - Text Răspuns. Parametrul correct_answers_index este de tip string, daca sunt mai multe răspunsuri, are forma: 'INDEX1,INDEX2,...'"},
            {"role": "user", "content": prompt_text}
        ],
        max_tokens=3000, # Adjusted to allow for more tokens if needed for completeness
        temperature=0.7
    )
```

Figura 32: Prompt-ul folosit pentru generarea întrebărilor

Prompt-ul anterior se folosește de API-ul pus la dispoziție de OpenAi, gpt-3.5-turbo. Mesajul pe care îl folosesc în generarea întrebărilor este ilustrată după secvența „message”. Conform testărilor curente, răspunsurile se generează mai corect atunci când sunt făcute mai puține request-uri asupra acestei comenzi. Am observat că dacă această structură se apelează foarte mult, repetat, scade drastic calitatea întrebărilor și răspunsurilor generate.

5.3 Metriki de evaluare

Pentru sistemul de generare a întrebărilor dezvoltat în cadrul lucrării se folosesc următoarele două metriki:

- Exact Match Ratio (EMR)
- Hamming Score

5.3.1 Exact Match Ratio

EMR este o metrică utilizată pentru a evalua performanța unui model de machine learning în sarcini de clasificare multi-etichete. Aceasta măsoară proporția de instanțe pentru care toate etichetele prezise coincid exact cu etichetele reale. Cu alte cuvinte, EMR indică cât de des modelul a prezis corect toate etichetele pentru o instanță dată.

5.3.2 Hamming Score

Distanța Hamming este o metrică utilizată pentru a măsura diferența dintre două secvențe de lungime egală. În contextul clasificării multi-etichete, aceasta reprezintă numărul de etichete diferite între setul de etichete prezise și setul de etichete reale pentru o instanță. Cu cât distanța Hamming este mai mică, cu atât predicțiile modelului sunt mai precise.

| Model | EMR | Hamming |
|-----------------------------|-------|---------|
| XLM-RoBERTa | 15.67 | 29.48 |
| BERT-base-romanian-cased-v1 | 22.34 | 35.12 |

Figura 33: Rezultatele modelelor antrenate

6 CONCLUZII

6.1 Concluzii

Lucrarea pune în evidență importanța generării de întrebări pentru proba scrisă a examenului de legislație auto. Aplicația dezvoltată utilizează modele AI și Machine Learning pentru a genera întrebări cu răspunsuri simple și răspunsuri multiple. Metoda de prezentarea a chestionarelor este una atractivă pentru învățare, care oferă satisfacție utilizatorului în rezolvarea testelor.

În cadrul lucrării se realizează o cercetare a performanței modelelor multilingvistice, precum XLM-RoBERTa și BERT-base-romanian-cased-v1, care pune în evidență neajunsurile dezvoltării actuale ale acestor tipuri de modele, în comparație cu API-urile oferite de către OpenAI.

Aplicația nu doar simplifică pregătirea pentru examenul de legislație auto, ci și siguranța rutieră. Oferind chestionare bine structurate și relevante, utilizatorii devin mai bine pregătiți pentru examen și pentru provocările viitoare ale conducerii auto. Acest lucru poate reduce numărul de accidente rutiere și promova un comportament responsabil pe drumurile publice.

În concluzie, aplicația web pentru generarea automată de chestionare pentru examenul de legislație auto poate reprezenta un progres semnificativ în educația auto. Datorită eficienței, personalizării și relevanței, această aplicație devine un instrument esențial pentru orice viitor șofer. Utilizarea pe scară largă a acestei tehnologii are potențialul de a schimba fundamental modul în care utilizatorii se pregătesc pentru examenul de legislație auto, contribuind astfel la formarea unor șoferi mai bine pregătiți și mai responsabili.

6.2 Directii viitoare

Pe viitor doresc să îmbunătățesc generarea de răspunsuri cu soluții multiple. Să îi pun la dispoziție modelului mai multe date despre legislație. Ideal legislația interpretată din mai multe surse, pentru a oferi o imagine de ansamblu mai completă. De asemenea, doresc să îmbunătățesc răspunsurile generate de aplicație prin feedback-ul primit atât de la utilizatori cât și de la personal experimentat din cadrul DRPCIV care se ocupă cu susținerea examenelor de acest tip.

Pentru ca platforma dezvoltată să fie una utilă și relevantă mulți ani de acum încolo, plănuiesc să adaug funcționalități noi de stimulare a utilizatorului pentru a învăța. Bazat pe modelul aplicației "Duolingo" prezentat anterior, am în vedere dezvoltarea paginilor de repetare a greșelilor, sau conținut de antrenament generat specific pentru fiecare utilizator. În funcție de nivelul de performanță în rezolvarea corectă a întrebărilor.

De asemnea, crearea unui mediu de învățare structurat pe secțiuni din legislație, cu cuestionare specific generate pentru fiecare categorie poate reprezenta o actualizare importantă. Utilizatorii ar putea să învețe mai structurat tot ce ține de legislație întâi, ca apoi să aibă acces direct la întrebările auto generate din text.

BIBLIOGRAFIE

- [1] Curs de legislație rutieră. <https://scoaladrpciv.ro/invata/curs-legislatie-rutiera>. Last accessed: 20 June 2024.
- [2] Pierduti pe drumuri: De ce este românul șofer pe viață și ce nu învățăm la școlile auto. <https://romania.europalibera.org/a/pierdu%C8%9Bi-pe-drumuri-de-ce-este-rom%C3%A2nul-%C8%99ofei-pe-via%C8%9B%C4%83-%C8%99i-ce-nu-%C3%AEnv%C4%83%C8%9B%C4%83m-la-%C8%99colile-auto-/31372513.html>. Last accessed: 21 June 2024.
- [3] Clinton Bicknell, Claire Brust, and Burr Settles. How duolingo's ai learns what you need to learn: The language-learning app tries to emulate a great human tutor. *IEEE Spectrum*, 60(3):28–33, 2023.
- [4] Ilaria Caponetto, Jeffrey Earp, and Michela Ott. Gamification and education: A literature review. In *European conference on games based learning*, volume 1, page 50. Academic Conferences International Limited, 2014.
- [5] Stefan Daniel Dumitrescu and Andrei-Marius Avram. Introducing ronec—the romanian named entity corpus. *arXiv preprint arXiv:1909.01247*, 2019.
- [6] James Elliott, Timothy M O'Brien, and Ryan Fowler. *Harnessing Hibernate: Step-by-step Guide to Java Persistence*. " O'Reilly Media, Inc.", 2008.
- [7] Rod Johnson, Juergen Hoeller, Keith Donald, Colin Sampaleanu, Rob Harrop, Thomas Risberg, Alef Arendsen, Darren Davison, Dmitriy Kopylenko, Mark Pollack, et al. The spring framework-reference documentation. *interface*, 21:27, 2004.
- [8] Sudheer Jonna and Oleg Varaksin. *Angular UI Development with PrimeNG*. Packt Publishing Ltd, 2017.
- [9] Diksha Khurana, Aditya Koli, Kiran Khatter, and Sukhdev Singh. Natural language processing: State of the art, current trends and challenges. *Multimedia tools and applications*, 82(3):3713–3744, 2023.
- [10] Bing Li, Yujie He, and Wenjin Xu. Cross-lingual named entity recognition using parallel corpus: A new approach using xlm-roberta alignment. *arXiv preprint arXiv:2101.11112*, 2021.

- [11] Anton Moiseev and Yakov Fain. *Angular Development with TypeScript*. Simon and Schuster, 2018.
- [12] Mitchell Shortt, Shantanu Tilak, Irina Kuznetcova, Bethany Martens, and Babatunde Akinkuolie. Gamification in mobile-assisted language learning: A systematic review of duolingo literature from public release of 2012 to early 2020. *Computer Assisted Language Learning*, 36(3):517–554, 2023.
- [13] Kevin P Yancey and Burr Settles. A sleeping, recovering bandit algorithm for optimizing recurring notifications. In *Proceedings of the 26th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*, pages 3008–3016, 2020.
- [14] Bingsheng Yao, Dakuo Wang, Tongshuang Wu, Tran Hoang, Branda Sun, Toby Jia-Jun Li, Mo Yu, and Ying Xu. It is ai's turn to ask human a question: Question and answer pair generation for children storybooks in fairytaleqa dataset. *arXiv preprint arXiv:2109.03423*, 2021.